音声対話 × Text-to-Motion × VRM

生成速度・会話の応答遅延・費用・研究室 PC での実行を検証

9 モデルの比較と LLM 英訳経路の追試

目標：生徒の音声を受け取り、
先生の発話と上半身ジェスチャーを自然なテンポで返す



更新版： 49 枚 / 全 60 本の動画を埋め込み / 追加実験は 31 枚目から

▶ 今回の追加実験へ（ 31 枚目）

生成単体の高速化は確認。会話の待ち時間には課題が残る

「生成が速い」と「会話の返答が速い」を分けて評価する

MotionLCM / RTX 4090

0.039 秒

初回を除く 4 区間の生成処理中央値

Kimodo / B300 ・ 20 steps

0.435 秒

約 5 秒の動作、 3 反復の中央値

Realtime との差

3.252 秒

B300 高速設定の会話実測・ 1 回

判断

次の焦点はモデル常駐・全文待ち・結果中継の短縮と、ジェスチャー品質の評価。

[R1] common/*/motion-generation.json [R3] benchmark/summary.json [R4] dialogue-times.csv

目標は、音声の返答と上半身ジェスチャーをそろえること

評価対象：録音した生徒音声 → Realtime の実応答 → 新規の動作生成 → VRM 表示

生徒の音声

先生、こんにちは！

→

Realtime

返答の音声・文字

→

動作モデル

新規の骨格を生成

→

VRM アバター

発話と動作を同期

応答テンポの目標

Realtime の最初の音声受信から、
骨格が使えるまでの追加待ちを 1 秒以内へ。

運用上の条件

上半身のみ表示／研究室 Windows で再現／
既存環境への変更を抑える。

[R2] audio-response-times.csv [R4] dialogue-*/measurement.json

7 モデルを実生成。出力する役割が異なるモデルを含む

話し手のジェスチャー、聞き手の全身反応、頭部反応を区別する

モデル	役割・出力	入力	今回の経路
Kimodo	話し手・全身	テキスト	公式オンライン／ B300
ARDY	話し手・全身	テキスト	Core8 ／ CPU 特徴＋ CUDA
MotionLCM	話し手・全身	テキスト	HumanML3D 系
MoMask	話し手・全身	テキスト	HumanML3D 系
MMM	話し手・全身	テキスト	HumanML3D 系
ReactMotion	聞き手・全身	テキスト	会話では生徒の認識文
MaAI	聞き手・頭部	音声	頭部パラメーター・うなずき

text-to-vrma ： ARDY の出力を VRMA へ変換する別経路。統合済み・同条件の実生成時間は未測定。

[R1] common-input-times.csv [R2] README.md [R8] model_compatibility.md

研究室 PC の制約を意識しつつ、 GPU 環境を段階的に拡張

RTX 4090 の制限実験と B300 実験は、 RTX 5070 / Windows の実測ではない

項目	研究室 PC	7 モデル比較のローカル GPU	Kimodo 常駐検証
GPU	RTX 5070 ×1	RTX 4090 ×1	B300 SXM6 AC ×1
VRAM	12GB	24GB ／ allocator 制限	公称 288GB
CPU	Ryzen 7 5700X	AMD EPYC 7K62	Intel Xeon 6740E
CPU 設定	8 コア 16 スレッド	推論 8 スレッド・ affinity 8	割当 24vCPU ／推論 8 スレッド
RAM	32GB	32GB のハード上限なし	251GB （ API 表示）
保存領域	SSD 1TB	クラウド作業領域	コンテナ 40 ＋作業 40GB
OS	Windows	Linux	Ubuntu 24.04

Kimodo の旧比較：公式オンライン GPU （ L40S 表示）。動画の描画：クラウド CPU / SwiftShader 。

[R5] reproducibility/hardware.json [R6] benchmark/hardware.json docs/windows_lab.md

共通の英語学習 5 区間と、生徒→先生の短い会話を使用

日本語・英語を含む利用者指定文を、英訳や動作命令に置換せず入力

1. こんにちは！
2. 今日も一緒に楽しく英語を勉強しましょう！
3. まずは英語で挨拶してみよう。
4. Hello! How are you today?
5. 元気なときは、 I'm happy! って言ってみてね。

会話の入力・返答

生徒（音声 1.9 秒）
「先生、こんにちは！」

先生（固定返答）
「こんにちは！今日も元気そうだね！英会話の練習を始めましょう」

音声入力の会話では、実際に受信した先生の返答文から、新規の動作を生成した。

計測を 3 段階に分け、 Realtime との差を明確に定義

同じ「生成時間」でも、読み込み・通信・描画を含むかで値が変わる

① 生成処理

入力テキスト処理＋動作生成＋骨格変換。
モデル読み込み・通信は原則別記。

② 会話の応答待ち

生徒の発話終了 → 骨格受信。
実際の API ・通信・起動等を含む。

③ MP4 書き出し

VRM 描画＋音声結合＋エンコード。
オフラインの成果物作成時間。

Realtime との差 ＝ 骨格が届いた時刻 − 最初の教師音声が届いた時刻

動画では骨格まで音声を待たせるため、発話・動作の開始は一致する。待ち時間そのものは残る。

共通 5 区間の記録：生成処理と動画化を別々に保存

GPU ・入力処理・役割が異なるため、この表だけでモデルの性能順位は決められない

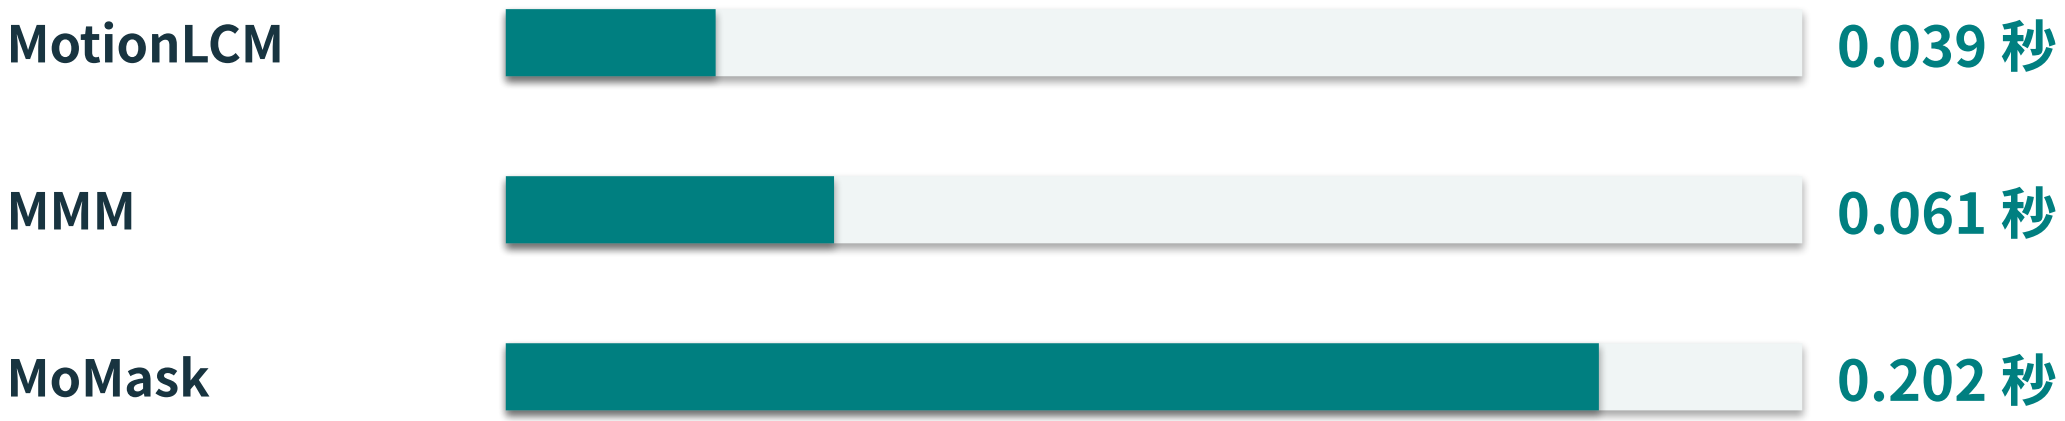
モデル	役割	生成処理・ 5 区間	MP4 描画・ CPU	生成の計測経路
Kimodo	話し手	51.409 秒	156.0 秒	公式オンライン・通信込み
ARDY	話し手	38.492 秒	160.2 秒	CPU 特徴＋ CUDA 生成
MotionLCM	話し手	0.570 秒	154.4 秒	CUDA 生成
MoMask	話し手	1.512 秒	154.8 秒	CUDA 生成
MMM	話し手	0.757 秒	156.5 秒	CUDA 生成
ReactMotion	聞き手・全身	2.597 秒	238.6 秒	CUDA 生成
MaAI	聞き手・頭部	8.063 秒	174.9 秒	CUDA 生成

同じ発話音声を各モデルで共有。生成後の再生時間調整・姿勢補間と、元の骨格を区別して保持。

[R1] common-input-times.csv / 値は各 5 区間の合計

同じ RTX 4090 ・入力 5 区間では MotionLCM が最短

初回を除く 4 区間の中央値。文と生成長は区間ごとに異なる（ 48 〜 72 フレーム）



モデル	初回区間の生成	残り 4 区間の範囲	Torch 最大割り当て
MotionLCM	0.414 秒	0.037 〜 0.041 秒	1.44GiB
MMM	0.527 秒	0.038 〜 0.071 秒	1.30GiB
MoMask	0.705 秒	0.196 〜 0.207 秒	0.89GiB

[R1] common/{motionlcm,mmm,momask}/segments/*/motion-generation.json

従来の会話経路では、起動・中継の待ちが大きかった

生徒の発話終了を 0 秒とする。各モデル 1 回、常駐化前の実測

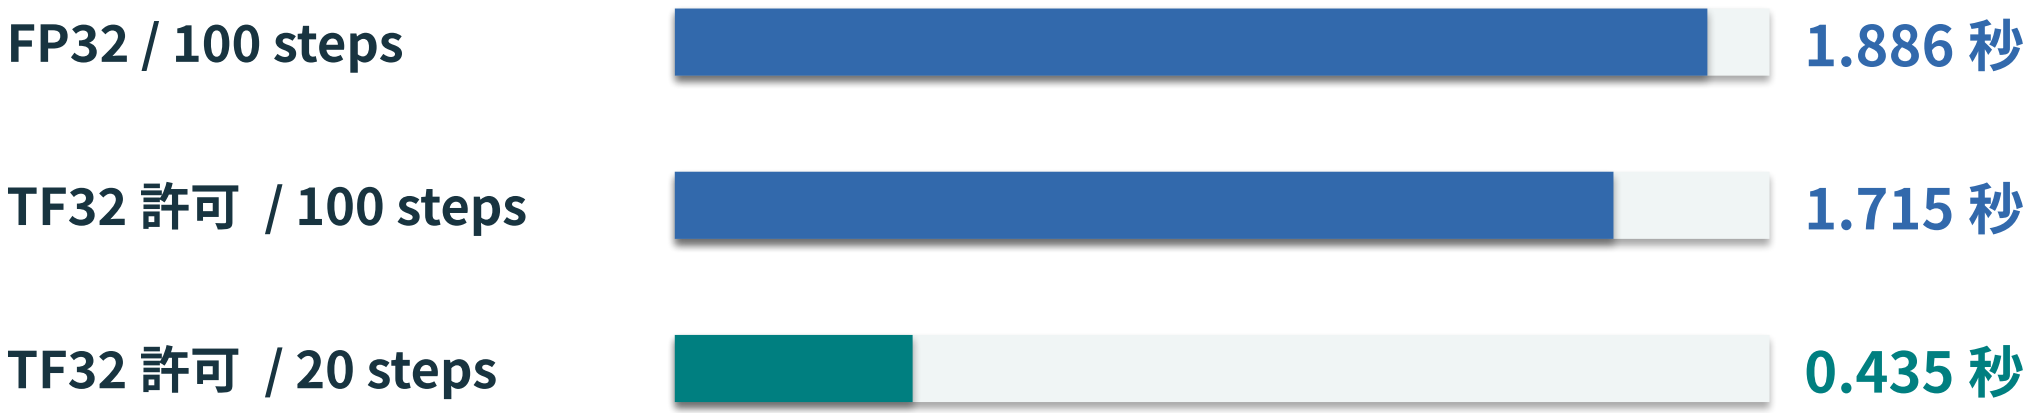
モデル	音声初受信（秒）	生成処理（秒）	動作完了観測（秒）	音声との差（秒）
Kimodo	0.811	10.561	15.395	14.584
ARDY	0.568	19.323	187.660	187.092
MotionLCM	1.049	0.421	19.242	18.193
MoMask	0.824	0.707	24.082	23.259
MMM	0.880	0.548	23.828	22.948
ReactMotion	1.218	1.000	18.998	17.780
MaAI	0.773	1.604	19.606	18.833

解釈：これは「モデルの純粋な速さ」の順位ではなく、当時の実装経路の応答待ちの記録。

[R2] audio-response-times.csv / Kimodo は公式オンライン、他は RTX 4090

Kimodo / B300 ： 20 ステップでは生成単体が 1 秒未満

同じ教師返答・ 149 フレーム（約 4.97 秒）・ batch=1 ・各設定 3 回の中央値



100→20 steps ：処理時間は約 77% 短縮

20 steps の画質・動作自然さが
100 steps と同等かは未評価。

常駐化の前提

キャッシュ済みモデル読込：約 40.2 秒
Torch 最大割り当て：約 15.3GiB

[R3] benchmark/summary.json ・ hardware.json / Kimodo-SOMA-RP-v1

B300 でも、骨格が届くまでの追加待ちは約 3.25 秒

別途実施した音声入力の会話：先生の全文を受信してから動作生成を開始



高速設定の追加待ち 3.252 秒 の内訳（残差による整理）

全文待ち 0.988 秒	送信まで 0.110 秒	骨格生成 0.496 秒	中継・結果受信等 1.658 秒

[R4] dialogue-{fp32-100,tf32-20}/measurement.json / 各 1 回・同一クライアント時計

上半身・正面 1080p のデモで、実測した待ち時間を確認

PowerPoint ：画像をクリックして動画再生 ／ PDF ：同梱 media フォルダーの MP4 を再生



通常 / FP32 ・ 100 steps

▶ 同梱MP4を開く



高速 / TF32 許可・ 20 steps

▶ 同梱MP4を開く

文ごとに発話・動作を同期し、連結する経路を実装

一括生成の既存コードは保持。文分割版・ ARDY 版・上半身版は独立した経路

区間 1
発話 ＋ 動作
同時に開始

→

区間 2
発話 ＋ 動作
同時に開始

→

区間 3
発話 ＋ 動作
同時に開始

→

区間 4
発話 ＋ 動作
同時に開始

→

区間 5
発話 ＋ 動作
同時に開始

同期・連結

区間の開始を同じフレームへそろえる。
境目の姿勢は最大 250ms 補間。
元の骨格・音声・時間記録を保持。

上半身表示の扱い

Kimodo は全身 77 関節を生成し、
上半身 67 関節を抽出。腰・脚を固定。
上半身のみを生成するモデルではない。

[R7] segmented/english-lesson*/README.md [R4] B300 README.md

B300 の 1 会話は約 5 円相当。ただし借りている間は連続課金

$8.99 / 時、 1 ドル 200 円で換算。モデル常駐済み・起動と待機の費用は別

料金の対象	通常 100 steps	高速 20 steps
入力音声開始→骨格受信	6.873 秒	5.837 秒
上記時間の GPU 料金	約 3.43 円	約 2.92 円
Realtime API ・ usage から算出	約 1.60 円	約 1.87 円
小計／会話（ ASR 等は別）	**約 5.04 円**	**約 4.78 円**

実運用： 1 時間 100 リクエストなら、 GPU 代だけで約 18 円／回 ＋ API 料金等。

検証一式の GPU ＋ストレージ概算： RTX 4090 約 500 円 ／ B300 約 925 円（ API 料金別）。
両 Pod とも終了・削除を確認済み。料金は確定請求額ではない。

[R4] usage ・入力開始〜骨格受信 [R9] trial-cleanup.json [P1] OpenAI 公式モデル料金

研究室 PC では、小型モデルから常駐実行を検証する

Windows / RTX 5070 12GB / RAM32GB 。セットアップ用スクリプトと専用仮想環境を用意

まず試す： MotionLCM / MMM / MoMask

4090 では Torch 最大割り当て約 0.9 〜 1.5GiB 。
Windows 実機で GPU 演算と生成時間を確認。

Kimodo ： CPU 側へテキスト処理を分離

今回の全 GPU 常駐は約 15.3GiB 。
12GB では同じ構成を使えない。

1

環境構築

既存スクリプト＋専用 venv

2

常駐化

重み・言語モデルを事前読込

3

同じ入力で計測

音声初受信・骨格受信を記録

4

品質を確認

意味適合・自然さ・つなぎ目

論文の順位との比較は限定的。品質を含む優劣は未確定

ユーザー提示の MoSCo 比較表と、今回の実験では入力・生成長・計測範囲が異なる

共通して登場するモデル	提示資料の AITS	今回・初回を除く 4 区間中央値
MotionLCM	0.030 秒	0.039 秒
MoMask	0.120 秒	0.202 秒

この 2 モデルの速度の順序は一致。ただし、論文の数値を再現したとは言えない。

未評価：日本語の意味適合／英語学習の発話に合う動作／動作自然さ／ FID ／
20 ステップの品質低下／連続会話での p50 ・ p95 。

[U1] ユーザー提示の MoSCo 紹介画像（ Table 1 ） [R1] MotionLCM ・ MoMask 実測

次は常駐・短区間化と、品質評価を組み合わせる

GPU の大型化だけでは、今回の会話経路の追加待ちを 1 秒以内にできなかった

確認できたこと

7 モデルの新規生成と動画化。
文単位の発話・動作同期と連結。
B300 の生成単体：最短中央値 0.435 秒。
会話の追加待ち：高速設定で 3.252 秒。

次の検証

① 全モデルを事前読込して比較
② 全文待ちを短い意味区間へ変更
③ 骨格を直接返し、保存処理を分離
④ 5070 実機＋反復計測＋品質評価

現時点の選定候補：速度重視は MotionLCM / MMM 。 Kimodo は品質確認と応答経路の改善を継続。

判断根拠： [R1–R4] / 右の施策は提案であり、達成時間の予測ではない

付録：初期調査からの到達点と、未測定の経路

古い「未実行」の記録を、後続の成功記録と混同しない

対象	初期調査・導入	今回の報告上の扱い
Kimodo	初期：公式オンラインの動作指示	後期：共通 5 文・音声会話・ B300 実生成
ARDY	初期：無条件 CPU 診断	後期： Horizon40 遠隔／ Core8 CUDA 実生成
text-to-vrma	ARDY エンジン選択・形式統合	モデルの同条件実生成時間は未測定
LoM / MIBURI / StreamTalk	公式コード・依存・重み配信を調査	今回の比較条件では実推論未検証
LLM-Gesture / ViBES body	資産・公開経路等を調査	今回の比較条件では実推論未検証
FreeTalker / AgentHands	コード調査／役割を確認	実生成の比較には未収録

公開コード・ダウンロード可能な重み・推論成功・会話品質の検証は、それぞれ別の到達点。

[R7] segmented/english-lesson*/README.md [R8] execution_results.md ・ model_compatibility.md

付録：初期の文分割デモは、発話に合わせた動作指示を使用

共通原文 5 区間の後期比較とは、入力・モデル・サービス・描画条件が異なる

項目	Kimodo 版	ARDY 版
モーションモデル	Kimodo SOMA-RP-v1	ARDY Core / Horizon40
利用経路	NVIDIA 公式オンライン	公開コミュニティ Space
骨格生成・ 5 区間	72.91 秒	115.29 秒
音声生成・今回分	25.32 秒	0 秒（同じ既存音声を共有）
連結込み MP4 書き出し	237.03 秒	1,038.91 秒
成功処理の合計	335.27 秒	1,154.20 秒
完成動画の長さ	14.133 秒	14.133 秒

▶ Kimodoの分割デモ

▶ ARDYの分割デモ

[R7] reports/segmented/english-lesson*/README.md / 成功処理の合計

付録：計測原本・固定バージョン・再現手順

Git リポジトリ： github.com/nk-an-nk/textToMotion / work　　実験コード基準： 3a37d6e

[R1・R2] 7モデル比較の記録

[R3・R4・R6] Kimodo / B300の計測・動画

[R5] GPU条件・ソースと重みのハッシュ

[R7] 文分割デモの入力・同期・計測

研究室Windowsのセットアップ手順

B300 ： PyTorch 2.8.0+cu129 / CUDA 12.9 / Python 3.12.3

ソース・重み revision ・ LoRA 各 448 テンソルを検証。元 NPZ ・骨格 JSON ・ WAV ・時刻・ usage を保存。
実装テスト： Python112 件／ JavaScript22 件。ライブ WebRTC ＋ローカル GPU の連続対話は未検証。

付録：全 18 本のデモ動画を PowerPoint 内に収録

モデル名・画像をクリックすると、会話と共通 5 文の動画スライドへ移動



▶ Kimodo



▶ ARDY



▶ MotionLCM



▶ MoMask



▶ MMM



▶ ReactMotion （聞き手）



▶ MaAI （聞き手）

▶ B300 比較へ

▶ 文分割デモへ

動画はすべて埋め込み

デモ動画： Kimodo / 話し手の動作

スライドショーで動画をクリックして再生。左右の動画は個別に再生できます。

生徒 → 先生の会話



発話終了→動作完了観測： 15.395 秒

▶ MP4を直接開く（補助リンク）

共通の英語学習 5 区間



5 区間の生成処理合計： 51.409 秒

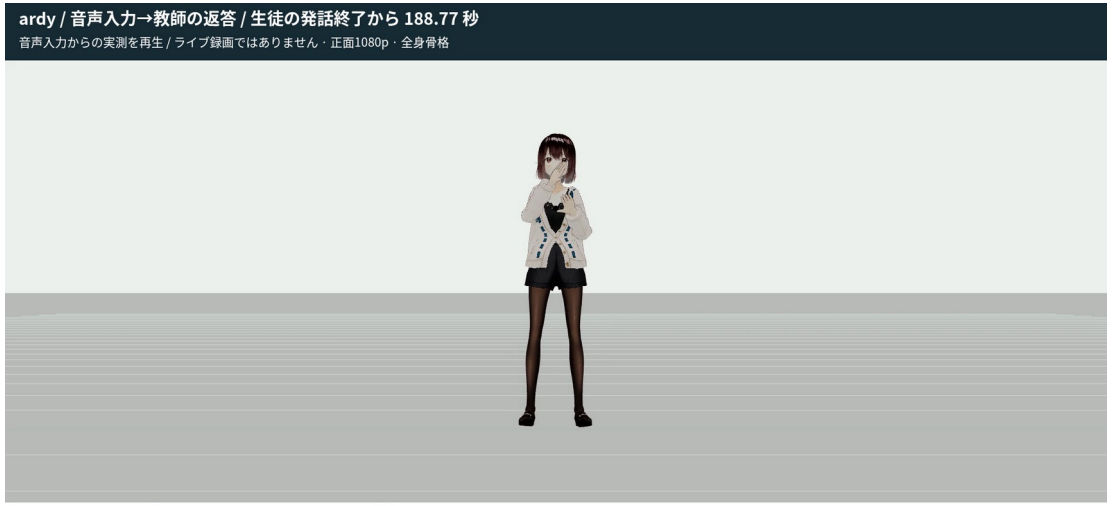
▶ MP4を直接開く（補助リンク）

← 動画目次へ

デモ動画： ARDY / 話し手の動作

スライドショーで動画をクリックして再生。左右の動画は個別に再生できます。

生徒 → 先生の会話



発話終了→動作完了観測： 187.660 秒

▶ MP4を直接開く（補助リンク）

共通の英語学習 5 区間



5 区間の生成処理合計： 38.492 秒

▶ MP4を直接開く（補助リンク）

← 動画目次へ

デモ動画： MotionLCM / 話し手の動作

スライドショーで動画をクリックして再生。左右の動画は個別に再生できます。

生徒 → 先生の会話



発話終了→動作完了観測： 19.242 秒

▶ MP4を直接開く（補助リンク）

共通の英語学習 5 区間



5 区間の生成処理合計： 0.570 秒

▶ MP4を直接開く（補助リンク）

← 動画目次へ

デモ動画： MoMask / 話し手の動作

スライドショーで動画をクリックして再生。左右の動画は個別に再生できます。

生徒 → 先生の会話



発話終了→動作完了観測： 24.082 秒

▶ MP4を直接開く（補助リンク）

共通の英語学習 5 区間



5 区間の生成処理合計： 1.512 秒

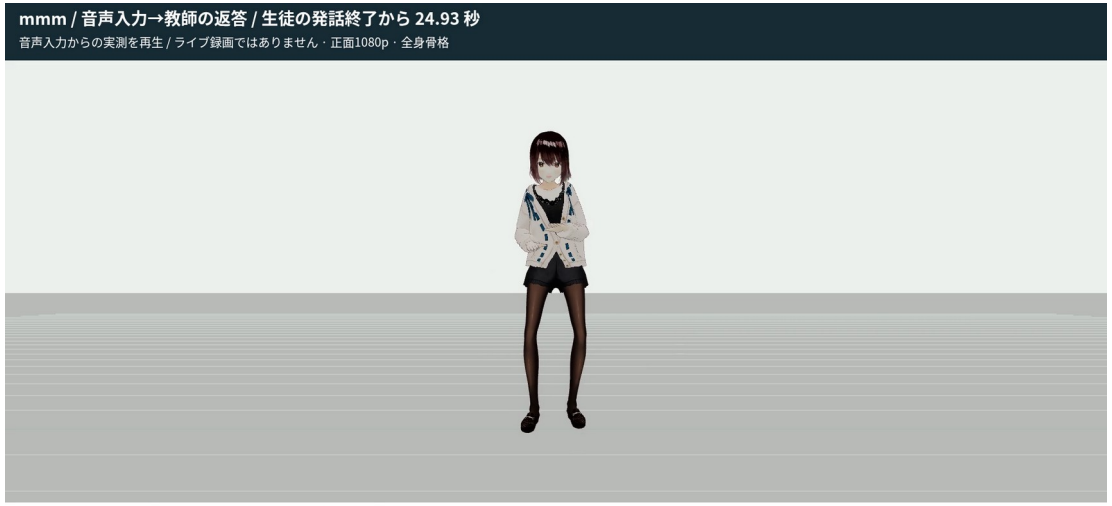
▶ MP4を直接開く（補助リンク）

← 動画目次へ

デモ動画： MMM / 話し手の動作

スライドショーで動画をクリックして再生。左右の動画は個別に再生できます。

生徒 → 先生の会話



発話終了→動作完了観測： 23.828 秒

▶ MP4を直接開く（補助リンク）

共通の英語学習 5 区間



5 区間の生成処理合計： 0.757 秒

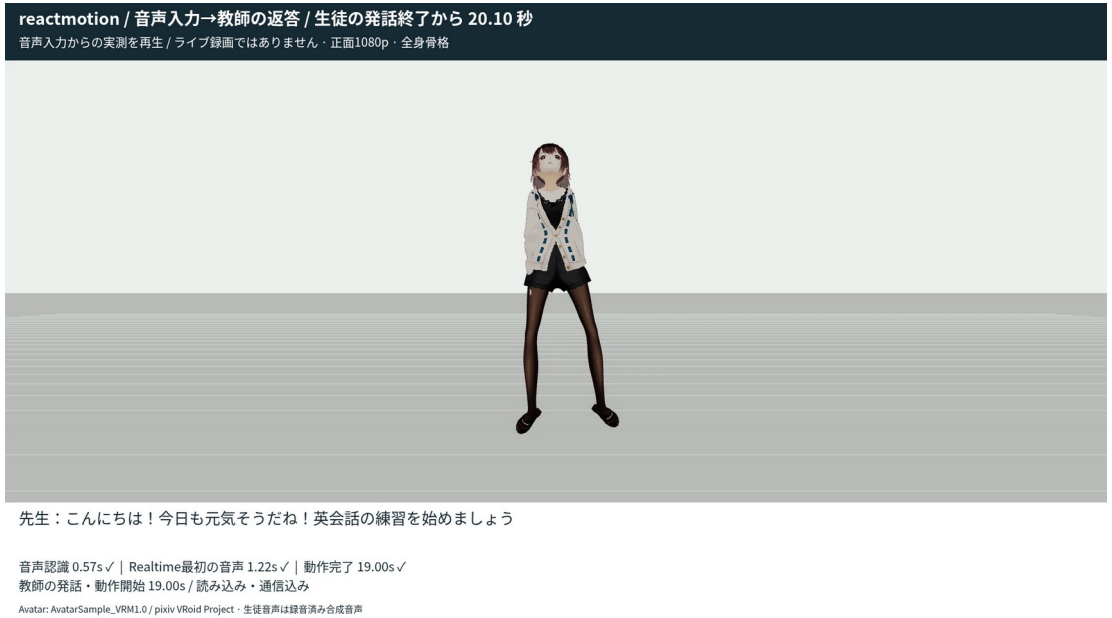
▶ MP4を直接開く（補助リンク）

← 動画目次へ

デモ動画： ReactMotion / 聞き手の反応

スライドショーで動画をクリックして再生。左右の動画は個別に再生できます。

生徒 → 先生の会話



発話終了→動作完了観測： 18.998 秒

▶ MP4を直接開く（補助リンク）

共通の英語学習 5 区間



5 区間の生成処理合計： 2.597 秒

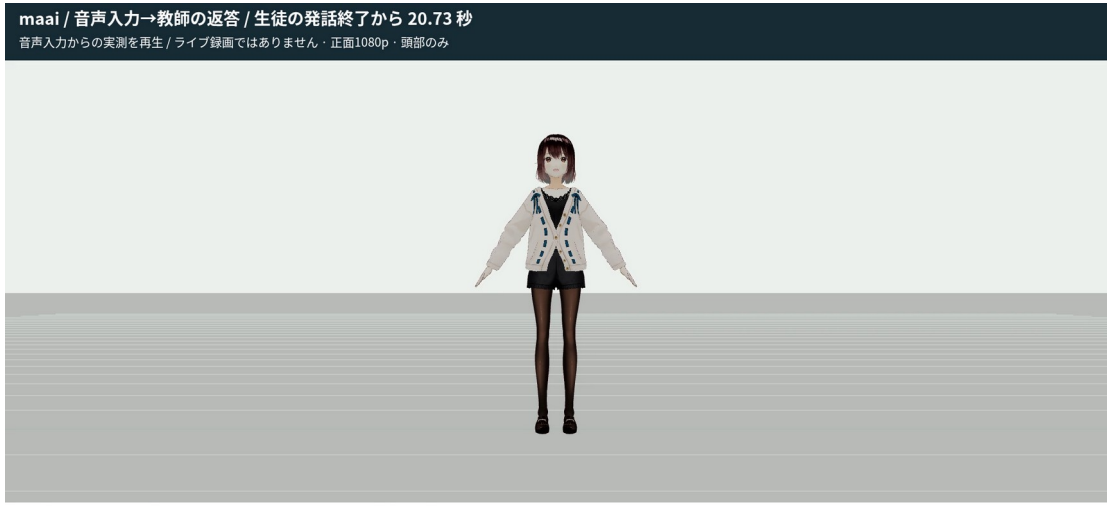
▶ MP4を直接開く（補助リンク）

← 動画目次へ

デモ動画： MaAI / 聞き手の反応

スライドショーで動画をクリックして再生。左右の動画は個別に再生できます。

生徒 → 先生の会話



発話終了→動作完了観測： 19.606 秒

▶ MP4を直接開く（補助リンク）

共通の英語学習 5 区間



5 区間の生成処理合計： 8.063 秒

▶ MP4を直接開く（補助リンク）

← 動画目次へ

デモ動画：文ごとの発話・ジェスチャーを同期して連結

初期の文分割デモ：発話に合わせた英語の動作指示を使用した別条件の実験

Kimodo / 公式オンライン



5 区間を連結・音声付き・ 14.133 秒

▶ MP4を直接開く（補助リンク）

ARDY / Horizon40



5 区間を連結・音声付き・ 14.133 秒

▶ MP4を直接開く（補助リンク）

← 動画目次へ

追加実験： LLM 英訳を挟み、 3 モデルを 2 環境で実生成

2026-10-16 / MoLingo ・ ReMoMask-2 ・ MoMask / 共通 5 区間と実音声の生徒→先生会話

常駐推論の測定

90 回

3 モデル ×2 環境 ×5 文 ×3 seed

実音声の会話測定

6 回

英訳・生成・通信を含む通し実測

追加した動画

42 本

本編 12 本＋区間単独 30 本

主な結果

生成中央値： MoMask 0.168 〜 0.300 秒 / ReMoMask-2 0.277 〜 0.494 秒 / MoLingo 2.217 〜 3.038 秒。

発話内容は保持し、動作モデルへ渡す文だけ LLM で英訳

共通 5 区間は同じ英訳を共有。動作指示への書き換えを行わない。音声・字幕は原文のまま。

区間	元の発話（音声・字幕）	LLM 英訳（動作モデル入力）	英訳
01	こんにちは！	Hello!	1.061s
02	今日も一緒に楽しく英語を勉強しましょう！	Let’s have fun studying English together again today!	1.075s
03	まずは英語で挨拶してみよう。	First, let's try greeting in English.	1.294s
04	Hello! How are you today?	Hello! How are you today?	0.998s
05	元気なときは、 I'm happy! って言ってみてね。	When you're feeling energetic, try saying, "I'm happy!"	1.430s

会話：受信した教師全文 → LLM 英訳 → 常駐モデル → 骨格受信。英訳も通し計測に含める。

常駐生成は MoMask が最短。会話の待ちは別に計測

生成中央値：英訳済み共通 5 区間 ×3 seed 。会話：各条件 1 回。すべて秒。

環境	モデル	骨格中央値	会話の英訳	発話終了→骨格	Realtime 差
RTX 4090 ・ 12GB 制限	MoLingo-263	2.217	1.587	6.175	+5.597
RTX 4090 ・ 12GB 制限	ReMoMask-2	0.277	0.936	3.302	+2.592
RTX 4090 ・ 12GB 制限	MoMask	0.168	1.167	3.337	+2.710
B300	MoLingo-263	3.038	1.499	7.756	+6.863
B300	ReMoMask-2	0.494	1.437	5.011	+4.112
B300	MoMask	0.300	1.112	4.217	+3.404

結果の読み方　今回の設定では、 3 モデルとも RTX 4090 の生成時間が B300 より短い。

研究室向けの 4090 と、前回と同じ B300 を比較

RTX 5070 / Windows の実機測定ではない。 RAM32GB の強制制限も設けていない。

項目	研究室実機（未測定）	今回の研究室向け代替	今回の上位 GPU
GPU	RTX 5070 12GB	RTX 4090 24GB	B300 SXM6 AC ・公称 288GB
CPU	Ryzen 7 5700X	AMD EPYC 75F3	Intel Xeon 6740E
CPU 制約	8 コア 16 スレッド	推論 8 / affinity8	推論 8 / affinity8
RAM	32GB	割当 62GB ・上限未設定	割当 251GB
OS	Windows	Ubuntu 24.04	Ubuntu 24.04
GPU 時給	研究室機	0.89 USD/h	8.99 USD/h

全身 22 関節を生成し、表示時に上半身を使用。腰・脚を固定し、元の骨格も保持。

Torch のピーク割当：約 0.89GiB （ MoMask ）、 1.75 〜 1.78GiB （ ReMoMask-2 ）、 3.10GiB （ MoLingo ）。

1 リクエストの参考料金を、 GPU ・音声・英訳に分ける

会話の usage から概算。 GPU は生徒音声開始→骨格受信を按分。 1 ドル 200 円。 ASR ・保存等は別。

環境	モデル	応答中 GPU	Realtime 音声	LLM 英訳	参考小計
RTX 4090 ・ 12GB 制限	MoLingo-263	¥0.399	¥1.783	¥0.502	¥2.684
RTX 4090 ・ 12GB 制限	ReMoMask-2	¥0.257	¥1.886	¥0.233	¥2.376
RTX 4090 ・ 12GB 制限	MoMask	¥0.259	¥1.830	¥0.290	¥2.379
B300	MoLingo-263	¥4.823	¥1.762	¥0.386	¥6.972
B300	ReMoMask-2	¥3.452	¥1.818	¥0.295	¥5.565
B300	MoMask	¥3.055	¥1.730	¥0.305	¥5.090

GPU レンタル概算：合計 $4.29

停止済み / 保持・ API 費用は別

保持： 10/17 15:37 ・ 16:04 JST

停止後 24h 保持／削除監視はクラウド側。

英訳で未知語を回避。発話に合う動作かは別に確認

同じ seed0 を採用し、見栄えに合わせた選び直しはしない。元の全身骨格を保存。



MoLingo-263

T5 の未知語： 0 件



ReMoMask-2

一部区間で大きな傾き



MoMask

会話出力に大きな体の傾き

速度・会話の待ち時間・ジェスチャー品質は分けて評価する。 FID や品質順位は未測定。

GPU の大型化だけでは、 Realtime との差 1 秒に届かない

英訳込み会話の追加待ちは 2.59 〜 6.86 秒。ネイティブ推論と待ちの内訳を分けて改善する。

確認したこと

原文を保持した LLM 英訳。
3 モデル ×2GPU の実生成。
90 回の常駐測定と会話 6 回。

次に測ること

短い意味区間からの生成開始。
翻訳・中継・保存の待ちを減らす。
5070 実機と発話への適合性。

動画付録：本編 12 本（ 38 〜 43 枚目） / 区間単独 30 本（ 44 〜 49 枚目）

全 60 本は PPTX に埋め込み済み。 PowerPoint で動画をクリックして再生。 PDF は静止画。

MoLingo-263 / 4090 ・ 12GB 制限：会話・共通 5 区間

各動画をクリックして個別に再生。教師の発話とジェスチャーは同じフレームから開始。

生徒 → 先生の実音声会話



骨格受信 6.175s / Realtime 差 +5.597s

共通の英語学習 5 区間



骨格生成中央値 2.217s / 英訳時間は別計測

ReMoMask-2 / 4090 ・ 12GB 制限：会話・共通 5 区間

各動画をクリックして個別に再生。教師の発話とジェスチャーは同じフレームから開始。

生徒 → 先生の実音声会話



骨格受信 3.302s / Realtime 差 +2.592s

共通の英語学習 5 区間



骨格生成中央値 0.277s / 英訳時間は別計測

MoMask / 4090 ・ 12GB 制限：会話・共通 5 区間

各動画をクリックして個別に再生。教師の発話とジェスチャーは同じフレームから開始。

生徒 → 先生の実音声会話



骨格受信 3.337s / Realtime 差 +2.710s

共通の英語学習 5 区間



骨格生成中央値 0.168s / 英訳時間は別計測

MoLingo-263 / B300 ：会話・共通 5 区間

各動画をクリックして個別に再生。教師の発話とジェスチャーは同じフレームから開始。

生徒 → 先生の実音声会話



骨格受信 7.756s / Realtime 差 +6.863s

共通の英語学習 5 区間



骨格生成中央値 3.038s / 英訳時間は別計測

ReMoMask-2 / B300 ：会話・共通 5 区間

各動画をクリックして個別に再生。教師の発話とジェスチャーは同じフレームから開始。

生徒 → 先生の実音声会話



骨格受信 5.011s / Realtime 差 +4.112s

共通の英語学習 5 区間



骨格生成中央値 0.494s / 英訳時間は別計測

MoMask / B300 ：会話・共通 5 区間

各動画をクリックして個別に再生。教師の発話とジェスチャーは同じフレームから開始。

生徒 → 先生の実音声会話



骨格受信 4.217s / Realtime 差 +3.404s

共通の英語学習 5 区間



骨格生成中央値 0.300s / 英訳時間は別計測

MoLingo-263 / 4090 ・ 12GB 制限：区間単独 5 本

全 5 区間の動画を埋め込み。 1 本ずつ再生してください。入力は原文を LLM で英訳した文。











原文の音声・字幕を保持

骨格入力のみ LLM 英訳。
フル HD ・ 30fps ・上半身表示。

ReMoMask-2 / 4090 ・ 12GB 制限：区間単独 5 本

全 5 区間の動画を埋め込み。 1 本ずつ再生してください。入力は原文を LLM で英訳した文。











原文の音声・字幕を保持

骨格入力のみ LLM 英訳。
フル HD ・ 30fps ・上半身表示。

MoMask / 4090 ・ 12GB 制限：区間単独 5 本

全 5 区間の動画を埋め込み。 1 本ずつ再生してください。入力は原文を LLM で英訳した文。











原文の音声・字幕を保持

骨格入力のみ LLM 英訳。
フル HD ・ 30fps ・上半身表示。

MoLingo-263 / B300 ：区間単独 5 本

全 5 区間の動画を埋め込み。 1 本ずつ再生してください。入力は原文を LLM で英訳した文。











原文の音声・字幕を保持

骨格入力のみ LLM 英訳。
フル HD ・ 30fps ・上半身表示。

ReMoMask-2 / B300 ：区間単独 5 本

全 5 区間の動画を埋め込み。 1 本ずつ再生してください。入力は原文を LLM で英訳した文。











原文の音声・字幕を保持

骨格入力のみ LLM 英訳。
フル HD ・ 30fps ・上半身表示。

MoMask / B300 ：区間単独 5 本

全 5 区間の動画を埋め込み。 1 本ずつ再生してください。入力は原文を LLM で英訳した文。











原文の音声・字幕を保持

骨格入力のみ LLM 英訳。
フル HD ・ 30fps ・上半身表示。